

Optimisation:

De l'estimation paramétrique à l'apprentissage,
une ballade entre théorie et pratique

S. Delprat

Chapitre 1 – Concepts mathématiques

Préambule

Qu'est ce qui est abordé dans cet ensemble de cours/TD ?

- Présentation de différents algorithmes d'optimisation
- Les formules mathématiques sous-jacentes

Qu'est ce qui n'est pas abordé dans cet ensemble de cours/TD ?

- Les preuves de convergence
- Les aspects liés à la mise en œuvre numérique : factorisation, inversion de matrice, etc.

Chapitre 1 - Concepts

- 1) Problématiques abordées en cours
- 2) Ecriture d'un problème d'optimisation
- 3) Minimisation non contrainte
- 4) Minimisation avec contraintes
- 5) Convexité

Introduction

- Une partie significative du travail d'ingénieur consiste à optimiser, améliorer un procédé.

Réduire la consommation d'énergie

Trouver la meilleure position

Améliorer les performances d'un système

Minimiser les pertes

Diminuer le temps de fabrication


Chercher le meilleur rapport qualité/prix

Lorsqu'un critère est défini, en général, il est possible de formuler un problème d'optimisation

Introduction

- Une autre classe de problèmes consiste à trouver les paramètres d'une fonction de manière à obtenir un résultat

Estimation paramétrique



$$y = f(u)$$

Régression polynomiale:

Trouver les coefficients p_i qui minimisent l'erreur de modèle

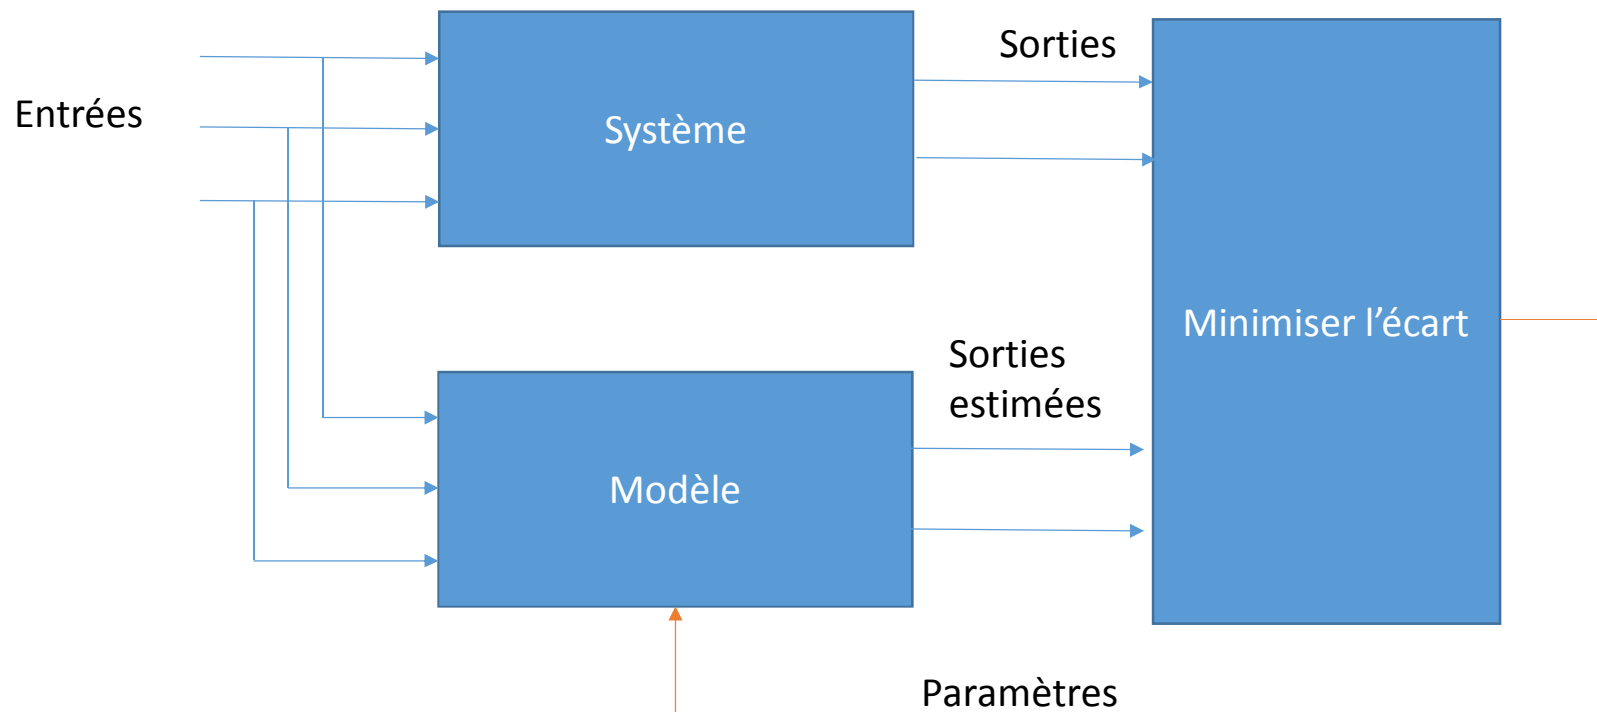
Modèle:
$$\hat{y} = \sum_{i=0}^{n-1} p_i u^i$$

Erreur de modèle
$$\varepsilon = \sum_{j=0}^{m-1} (y_j - \hat{y}_j)^2$$

Introduction

- Une autre classe de problème consiste à trouver les paramètres d'une fonction de manière à obtenir un résultat

Estimation paramétrique



Introduction

- Comment faire si on n'a peu ou pas d'information sur la fonction f ?
 - ⇒ Utiliser un modèle « suffisamment flexible » pour s'adapter à n'importe quelle fonction f *(avec quelques restrictions quand même)*.
 - ⇒ Propriété d'approximation universelle

Une approche : les réseaux de neurones...

Applications :

Reconnaissance d'images : classification, interprétation de scènes, etc.
Commande de systèmes
Traduction de texte
Compréhension du langage naturel, etc.

En 2017 ces fonctionnalités requièrent l'optimisation de quelques millions de paramètres

- ⇒ Il faut beaucoup de données d'entrées « big data »
 - ⇒ Temps d'exécution de l'algorithme d'optimisation : quelques semaines sur des super calculateurs
- Mais le modèle résultat est exploitable en temps réel

Chapitre 1 - Concepts

- 1) Problématiques abordées en cours
- 2) **Ecriture d'un problème d'optimisation**
- 3) Minimisation non contrainte
- 4) Minimisation avec contraintes
- 5) Convexité

Introduction – L'optimisation pourquoi faire?

- Variables: Ce que l'on veut trouver

Scalaire ou vecteur

$$x \in \mathbb{R}$$

1 variable réelle

Binaire, entier ou Réel

$$x \in \mathbb{R}^n$$

n variables réelles

$$x \in \mathbb{R} \times \{0,1\}^2$$

1 variable réelle + 2 variables binaires

etc.

- Critère: Ce que l'on veut minimiser/maximiser

C'est une fonction qui doit pouvoir être évaluée.

Elle peut être :

- Linéaire / non linéaire
- Différentiable / non différentiable
- Définie sur un support bornée ou non
- Convexe ou non
- Non linéaire, non différentiable:

$$J = 2x + 2$$

Linéaire , différentiable

$$J = x^2$$

Non linéaire , différentiable

$$J = \text{mod}(x, 4)$$

Non linéaire , non différentiable

Simulation simulink, CFD, etc.


Introduction – L'optimisation pourquoi faire?

- Contraintes: Dans quel espace doit-on chercher la solution


Egalités	$2x_1 + 3x_2 = 0$	$x_1^2 + x_2^2 = 2$
----------	-------------------	---------------------

Inégalités	$2x_1 + 3x_2 > 0$	$x_1^2 + x_2^2 = 2$
------------	-------------------	---------------------


$$\max(|x_1|, |x_2|) < 5$$



$$\max(x_1^2 + x_2^2) < 16$$



$$(\cos(x_1^2)x_2)^2 < 5$$



Introduction – L'optimisation pourquoi faire?

- **Contraintes:** Dans quel espace doit on chercher la solution

Contraintes linéaires:

- Égalité : $Ax = b$

Ce type de contrainte définit un hyper-plan (droite, plan, etc.)

- Inégalité : $Ax > b$

Définit l'espace au dessus ou dessous de l'hyper plan

Un peu de vocabulaire pour commencer

On cherche à minimiser un critère $f(x)$. L'objectif est donc de trouver :


- Le minimum/maximum de f $J = \min_{\text{dom}(f)} f(x)$ $J = \max_{\text{dom}(f)} f(x)$

- La valeur x^* qui minimise/maximise f : $x^* = \arg \min_{\text{dom}(f)} f(x)$ $x^* = \arg \max_{\text{dom}(f)} f(x)$

$$f(x) = (x+3)^2 + (y-2)^2 + 4$$

$$J = \min_{\text{dom}(f)} f(x) = 4$$

$$x^* = \arg \min_{\text{dom}(f)} f(x) = (-3, 2)^T$$



Un peu de vocabulaire pour commencer

Soit une fonction $f : S \rightarrow \mathbb{R}$ définie sur un sous ensemble $S \subseteq \mathbb{R}^n$

Minimum global:



$x^* \in S$ est un minimum global de f sur S si $f(x^*) \leq f(x) \quad \forall x \in S$

$x^* \in S$ est un minimum global strict de f sur S si $f(x^*) < f(x) \quad \forall x \in S / x^*$

Maximum global:

$x^* \in S$ est un maximum global de f sur S si $f(x^*) \geq f(x) \quad \forall x \in S$

$x^* \in S$ est un maximum global strict de f sur S si $f(x^*) > f(x) \quad \forall x \in S / x^*$



Un peu de vocabulaire pour commencer


Attention :

$\max_{x \in S} f(x)$ est unique

Mais la fonction f peut admettre plusieurs minimums globaux:


$\arg \max_{x \in S} f(x)$ n'est pas unique !!

NB: Dans le cadre de ce cours, on supposera que la fonction f atteint son maximum/minimum : on ne traite pas le cas des asymptotes



$$\max_{x \in S} f(x) = 4 \quad \arg \max_{x \in S} f(x) = \{5.1, 6.1\}$$

Plusieurs maxima globaux



Plusieurs minimums globaux

Un peu de vocabulaire pour commencer

Soit une fonction $f : S \rightarrow \mathbb{R}$ définie sur un sous ensemble $S \subseteq \mathbb{R}^n$

Boule de centre x^* de rayon r

Minimum local:

$x^* \in S$ est un minimum *local* de f sur S si il existe $r > 0$ tel que $f(x^*) \leq f(x) \quad \forall x \in S \cap B(x^*, r)$

$x^* \in S$ est un minimum *local strict* de f sur S si il existe $r > 0$ tel que $f(x^*) < f(x) \quad \forall x \in S \cap B(x^*, r) / x^*$


Maximum local:

$x^* \in S$ est un maximum *local* de f sur S si il existe $r > 0$ tel que $f(x^*) \geq f(x) \quad \forall x \in S \cap B(x^*, r)$


$x^* \in S$ est un maximum *local strict* de f sur S si il existe $r > 0$ tel que $f(x^*) > f(x) \quad \forall x \in S \cap B(x^*, r) / x^*$

NB: un minimum (resp. maximum) global est nécessairement un minimum (resp. maximum) local

$f(x)$ Minimum global



$f(x)$ Minimum global





Propriétés

Soit une fonction $f : S \rightarrow \mathbb{R}$ définie sur un sous ensemble $S \subseteq \mathbb{R}^n$

On peut facilement passer d'un problème de minimisation à un problème de maximisation:

$$\min_{x \in S} f(x) = -\max_{x \in S} (-f(x)) \quad \arg \min_{x \in S} f(x) = \arg \max_{x \in S} (-f(x))$$

Et l'inverse: $\max_{x \in S} f(x) = -\min_{x \in S} (-f(x)) \quad \arg \max_{x \in S} f(x) = \arg \min_{x \in S} (-f(x))$



Chapitre 1 - Concepts

- 1) Problématiques abordées en cours
- 2) Ecriture d'un problème d'optimisation
- 3) Minimisation non contrainte
- 4) Minimisation avec contraintes
- 5) Convexité

Gradient

Soit une fonction $f : \mathbb{R}^n \rightarrow \mathbb{R}$ de classe \mathcal{C}^1

Gradient d'une fonction:

Généralisation de la notion de dérivée aux fonctions de plusieurs variables.



En chaque point de l'espace, le gradient est un vecteur qui pointe dans la direction de la plus grande « croissance » de f .

$$\vec{\nabla} f(x) = \nabla f(x) = \begin{pmatrix} \frac{\partial f}{\partial x_1} \\ \vdots \\ \frac{\partial f}{\partial x_n} \end{pmatrix}$$

Opérateur « Nabla »

$$f(x) = x_1 e^{-x_1^2 - x_2^2}$$

$$\nabla f(x) = \begin{pmatrix} \frac{\partial f}{\partial x_1} = -(2x_1 - 1)e^{-x_1^2 - x_2^2} \\ \frac{\partial f}{\partial x_2} = -2x_1 x_2 e^{-x_1^2 - x_2^2} \end{pmatrix}$$



Gradient

Utilisation de la toolbox symbolique de Matlab:

```
clear all  
close all;  
clc;
```

« Nettoyage » écran, mémoire

```
% Calcul symbolique  
syms x1 x2 real
```

Création des objets symboliques

```
f = x1.*exp(-x1^2-x2^2);  
g = gradient(f, [x1, x2]);
```

Définition de la fonction
Calcul gradient (symbolique)

```
% Création de fonctions  
g1=symfun(g(1), [x1,x2]);  
g2=symfun(g(2), [x1,x2]);  
f=symfun(f, [x1,x2]);
```

Création de fonctions à partir des expressions symboliques

```
% Evaluation numérique des fonctions sur une grille  
[X1, X2] = meshgrid(-2:.2:2,-2:.1.5:2);  
F = f(X1,X2);  
G1 = g1(X1,X2);  
G2 = g2(X1,X2);
```

Définition d'une « grille » carrée
+ évaluation des fonctions et du gradient sur la grille

```
% Conversion symbolique => double  
F=double(F);  
G1=double(G1);  
G2=double(G2);
```

Conversion du résultat (nombre
« symbolique ») en double



```
>> f  
f(x1, x2) =  
x1*exp(- x1^2 - x2^2)  
>> g  
g =  
exp(- x1^2 - x2^2) - 2*x1^2*exp(- x1^2 - x2^2)  
-2*x1*x2*exp(- x1^2 - x2^2)
```

Gradient

Utilisation de la toolbox symbolique de Matlab:

```
% Affichages
figure;
surf(X1,X2,F);
hold on;
xlabel('x_1');
xlabel('x_2');

figure;
contour(X1,X2,F);
hold on;
quiver(X1, X2, G1, G2);
xlabel('x_1');
xlabel('x_2');
```



Savoir-faire n°1 :

- Définir une fonction symbolique
- Calculer et afficher le gradient d'une fonction de deux variables réelles


Conditions nécessaires d'optimalité

Soit une fonction $f : \mathbb{R} \rightarrow \mathbb{R}$ de classe \mathcal{C}^1

Soit x^* un minimum ou maximum **local**:

Condition nécessaire au premier ordre: $\nabla f(x^*) = 0$

Les valeurs x^* telles que $\nabla f(x^*) = 0$ sont appelées *points stationnaires* de f .



Les minimum globaux sont aussi des minimum locaux

Les minimums locaux sont aussi des points stationnaires

⇒ La condition au premier ordre ne permet pas immédiatement de trouver le minimum global

⇒ il faut faire le tri parmi les valeurs possibles

Calcul de points stationnaires

Utilisation de la toolbox symbolique de Matlab:

```
clear all  
close all;  
clc;
```

« Nettoyage » écran, mémoire

```
syms x real
```

```
% Fonction à étudier
```

```
f=x^4 - (163*x^3)/10 + (2463*x^2)/25 - (6544*x)/25 + 6448/25;
```

Définition de la fonction à étudier

```
% Calcul de la dérivée
```

```
dfdx=diff(f,x)
```

Calcul symbolique de $\frac{df}{dx}$

```
% Recherche des points stationnaires
```

```
x_stat=solve(dfdx,x)
```

Tentative de résolution de $\frac{df(x)}{dx} = 0$

```
% Tracé de la fonction
```

```
X = (2.5:.02:5.7);  
f=symfun(f,x);  
F = f(X);  
F = double(F);
```

Calculs de quelques points $(x_i, f(x_i,))$

```
figure;  
plot(X,F,'r');  
hold on;  
plot(x_stat,f(x_stat),'b*');  
grid on;  
legend('f(x)', 'pts stationnaires');
```

Affichage

Savoir-faire n°2 : calculer les points stationnaires d'une fonction

Conditions nécessaires d'optimalité

Une matrice $M \in \mathbb{R}^{n \times n}$ est dite *définie positive* si toutes ses valeurs propres sont strictement positives

Si $X > 0$ est régulière alors: $X^T M X > 0$

Une matrice $M \in \mathbb{R}^{n \times n}$ est dite *définie négative* si toutes ses valeurs propres sont strictement positives

Si $X > 0$ est régulière alors: $X^T M X < 0$

Le Hessien d'une fonction $f : \mathbb{R} \rightarrow \mathbb{R}$ de classe \mathcal{C}^2 est défini par: $\nabla^2 f(x) = \left(\frac{\partial^2 f}{\partial x_i \partial x_j} \right) \quad i, j = 1..n$

(C'est donc la Jacobienne du gradient).

Soit une fonction $f : \mathbb{R} \rightarrow \mathbb{R}$ de classe \mathcal{C}^2 .

Soit x^* un minimum ou maximum **local**.

Condition *suffisante* au second ordre:

$\nabla^2 f(x^*) > 0$: minimum local

$\nabla^2 f(x^*) < 0$: maximum local

$\nabla^2 f(x^*) = 0$: point de selle

Conditions nécessaires d'optimalité


Fonction : $f(x) = a(x_1^2 - 0.5^2) + b(x_2^2 - 0.5^2)$

Gradient : $\nabla f(x) = \begin{pmatrix} 2ax_1 \\ 2bx_2 \end{pmatrix}$ $\nabla f(x) = 0 \Leftrightarrow x = (0,0)$

Hessien : $\nabla^2 f(x) = \begin{pmatrix} 2a & 0 \\ 0 & 2b \end{pmatrix}$ Valeurs propres : $vp(\nabla^2 f(x)) = (2a, 2b)$


$a=1, b=1$ $\nabla^2 f(x) > 0$

Minimum




$a=1, b=-1$ $\nabla^2 f(x)$ indéfini

Point de selle



$a=-1, b=-1$ $\nabla^2 f(x) < 0$

Maximum

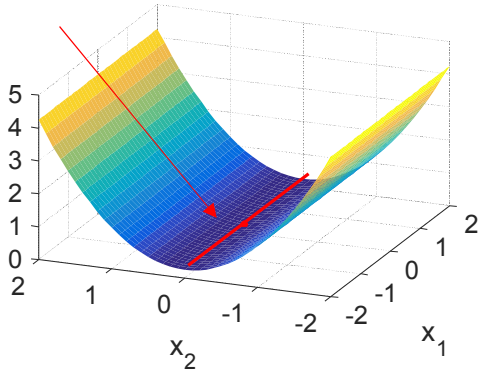
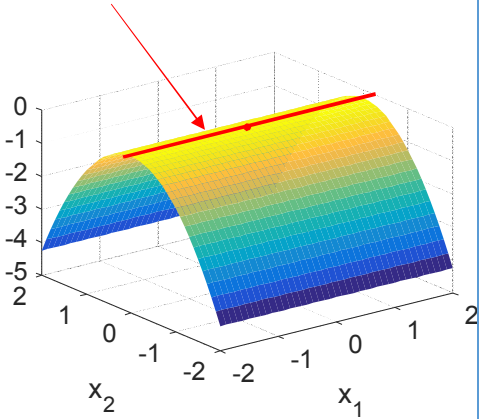


Conditions nécessaires d'optimalité

Fonction : $f(x) = a(x_1^2 - 0.5^2) + b(x_2^2 - 0.5^2)$

Gradient : $\nabla f(x) = \begin{pmatrix} 2ax_1 \\ 2bx_2 \end{pmatrix}$ $\nabla f(x) = 0 \Leftrightarrow x = (0,0)$

Hessien : $\nabla^2 f(x) = \begin{pmatrix} 2a & 0 \\ 0 & 2b \end{pmatrix}$ Valeurs propres : $vp(\nabla^2 f(x)) = (2a, 2b)$

$a = 0, b = 1$ $\nabla^2 f(x) \geq 0$	$a = 0, b = -1$ $\nabla^2 f(x) \leq 0$
<p>Minimums</p> 	<p>Maximums</p> 

Minimisation non contrainte

Problème à résoudre

Domaine non borné

Soit une fonction de classe \mathcal{C}^1 : $f : \mathbb{R}^n \rightarrow \mathbb{R}$

On cherche : $x^* = \arg \min_{x \in \mathbb{R}^n} f(x)$

Et $f(x^*) = \min_{x \in \mathbb{R}^n} f(x)$

Algorithme (naif):

1) Calculer l'ensemble des points stationnaires $\Phi_{stat} = \{x \in \mathbb{R}^n \mid \nabla f(x) = 0\}$

2) Garder uniquement les minimums locaux $\Phi_{min} = \{x \in \Phi_{stat} \mid \nabla^2 f(x) > 0\}$

2) Par énumération, trouver l'argmin de f $x^* = \arg \min_{x \in \Phi_{min}} f(x)$

Minimisation non contrainte

Problème à résoudre $x^* = \arg \min_{x \in \mathbb{R}^n} f(x)$

$$f(x) = \left((x_1)^2 + (x_2)^2 \right) e^{-(x_1)^2 - (x_2)^2}$$


$$\nabla f(x) = \begin{pmatrix} 2x_1 e^{-(x_1)^2 - (x_2)^2} - 2x_1 \left((x_1)^2 + (x_2)^2 \right) e^{-(x_1)^2 - (x_2)^2} \\ 2x_2 e^{-(x_1)^2 - (x_2)^2} - 2x_2 \left((x_1)^2 + (x_2)^2 \right) e^{-(x_1)^2 - (x_2)^2} \end{pmatrix}$$

$$\nabla f(x) = 0 \Leftrightarrow \begin{pmatrix} x_1 - x_1 \left((x_1)^2 + (x_2)^2 \right) \\ x_2 - x_2 \left((x_1)^2 + (x_2)^2 \right) \end{pmatrix} = 0$$

$$\nabla f(x) = 0 \Leftrightarrow \begin{pmatrix} x_1 \left(1 - (x_1)^2 - (x_2)^2 \right) \\ x_2 \left(1 - (x_1)^2 - (x_2)^2 \right) \end{pmatrix} = 0$$

1 Racine évidente $x = (0,0)$

Tout le cercle de centre $(0,0)$ et de rayon 1 : $1 - (x_1)^2 - (x_2)^2 = 0$



Minimisation non contrainte

$$\text{Gradient } \nabla f(x) = \begin{pmatrix} 2x_1(1 - (x_1)^2 - (x_2)^2)e^{-(x_1)^2 - (x_2)^2} \\ 2x_2(1 - (x_1)^2 - (x_2)^2)e^{-(x_1)^2 - (x_2)^2} \end{pmatrix}$$

$$\text{Hessien: } \nabla^2 f(x) = \begin{pmatrix} 2e^{-(x_1)^2 - (x_2)^2} (2(x_1)^4 + 2(x_1)^2(x_2)^2 - 5(x_1)^2 - (x_2)^2 + 1) & 4x_1x_2e^{-(x_1)^2 - (x_2)^2} ((x_1)^2 + (x_2)^2 - 2) \\ 4x_1x_2e^{-(x_1)^2 - (x_2)^2} ((x_1)^2 + (x_2)^2 - 2) & 2e^{-(x_1)^2 - (x_2)^2} (2(x_1)^2(x_2)^2 - (x_1)^2 + 2(x_2)^4 - 5(x_2)^2 + 1) \end{pmatrix}$$

Valeurs propres : (calcul symbolique) `Lambda=simplify(eig(d2fdx2)) ;`

$$\lambda_1 = 2e^{-(x_1)^2 - (x_2)^2} (2(x_1)^4 + 4(x_1)^2(x_2)^2 - 5(x_1)^2 + 2(x_2)^4 - 5(x_2)^2 + 1)$$

$$\lambda_2 = -2e^{-(x_1)^2 - (x_2)^2} ((x_1)^2 + (x_2)^2 - 1)$$

Sur le cercle $(x_1)^2 + (x_2)^2 = 1$ λ_2 est nul \Rightarrow le Hessien n'est ni défini positif ni défini négatif donc le cercle n'est pas un minium de f .

En $(0,0)$, $\lambda_1 = \lambda_2 = 2 \Rightarrow$ le Hessien est positif donc $(0,0)$ est un minimum local de f .

En toute rigueur, il faudrait étudier le comportement asymptotique de f pour conclure que $(0,0)$ est un minimum *global*

Minimisation non contrainte

```
clear all
close all;
clc;
syms x1 x2

% Fonction à minimiser
f = exp(-x1^2-x2^2)*(x1^2+x2^2);
F = symfun(f,[x1 x2]);

dfdx=gradient(f,[x1,x2]);
d2fdx2= hessian(f,[x1,x2]);
d2fdx2=symfun(d2fdx2,[x1,x2]);


% Valeurs propres du Hession
lambda=simplify(eig(d2fdx2));
lambda=symfun(lambda,[x1 x2]);

% Valeurs numérique pour affichage
[X1, X2] = meshgrid(-3:.1:2,-3:.1:2);
F = double(f(X1,X2));
figure;
surf(X1,X2,F,'EdgeColor','none');
hold on;
xlabel('x_1');
ylabel('x_2');
hold on;

% Tracé du cercle
theta=0:0.1:2*pi+0.2;
xx=sin(theta);
yy=cos(theta);
zz=f(xx,yy);
plot3(xx,yy,zz,'r','linewidth',2);

% Affichage du gradient
figure;
contour(X1,X2,F);
hold on;
[X1, X2] = meshgrid(-2.5:.1:2.5,-2.5:.1:2.5);
g=gradient(f);
gg=g(X1,X2);
G1 = double(gg{1});
G2 = double(gg{2});
quiver(X1, X2, G1, G2);
xlabel('x_1');
ylabel('x_2');
```

Visualisation du gradient



Savoir-faire n°3 : Calcul symbolique

`hessian(f,[x1 x2])` : calcul du hessien de $f(x_1, x_2)$

`eig(Matrice)` : calcul des valeurs propres

`simplify(expr)` : simplification symbolique de l'expression

Chapitre 1 - Concepts

- 1) Problématiques abordées en cours
- 2) Ecriture d'un problème d'optimisation
- 3) Minimisation non contrainte
- 4) Minimisation avec contraintes
- 5) Convexité

Minimisation avec contraintes égalités

On considère le problème suivant avec contrainte égalité:

Soient les fonctions de classe \mathcal{C}^1 : $f : \mathbb{R}^n \rightarrow \mathbb{R}$ et $h : \mathbb{R}^m \rightarrow \mathbb{R}$

Critère: $J = \min_{x \in \mathbb{R}^n} f(x)$

Sous la contrainte : $h(x) = 0$

=> On restreint la recherche à un sous ensemble de \mathbb{R}^n

Soit x^{nc} la solution du problème non contraint: $x^{nc} = \arg \min_{x \in \mathbb{R}^n} f(x)$

Propriété: Si $h(x^{nc}) = 0$ Alors x^{nc} est aussi la solution du problème contraint

Minimisation avec contraintes égalités

Rappel : résolution sans contraintes $J = \min_{x \in \mathbb{R}^n} f(x)$

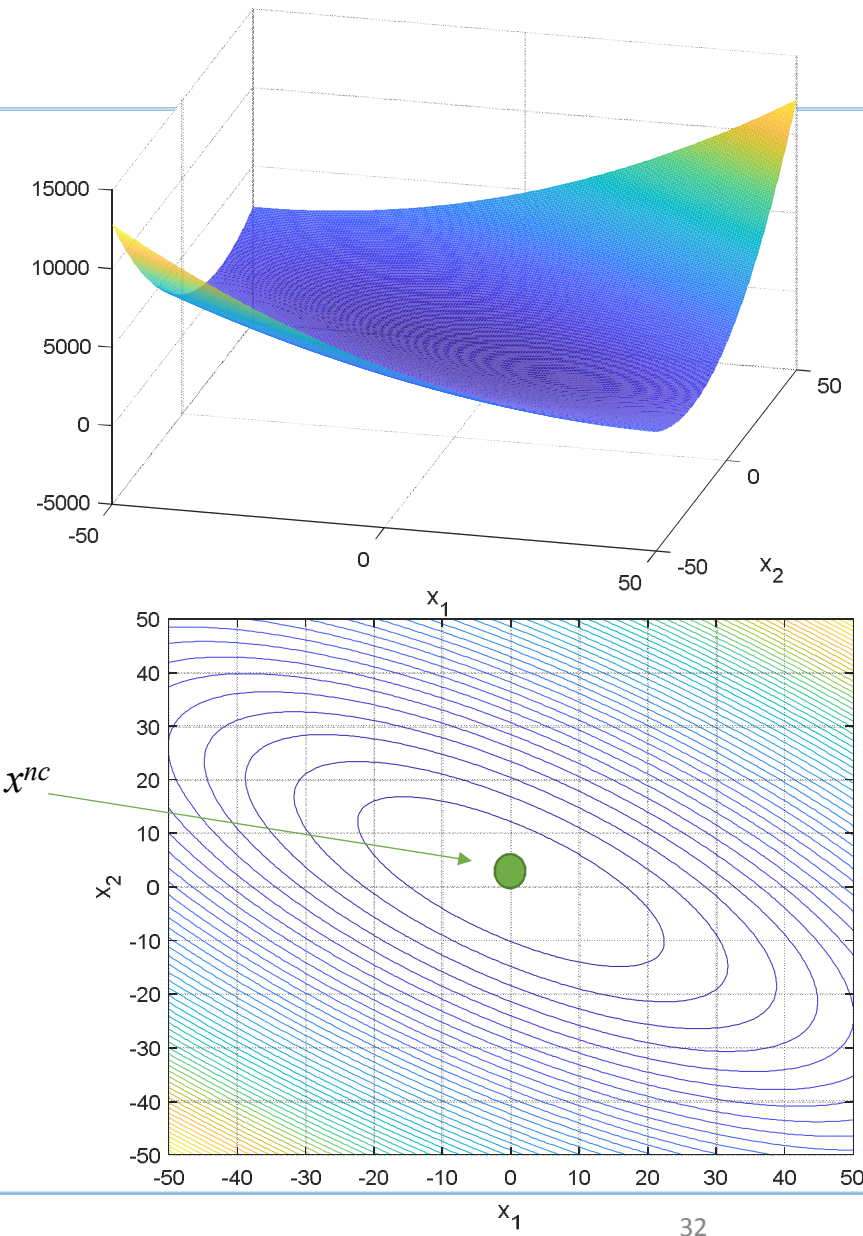
Soit $f(x) = x_1^2 + 2x_2^2 + 2x_1x_2 - 2x_1 - 4x_2$

$$\nabla f(x) = \begin{pmatrix} 2x_1 + 2x_2 - 2 \\ 2x_1 + 4x_2 - 4 \end{pmatrix} = 0$$

$$\nabla f(x) = \begin{pmatrix} 2x_1 + 2x_2 - 2 \\ 2x_1 + 4x_2 - 4 \end{pmatrix} = 0 \Leftrightarrow (x_1, x_2) = (0, 1)$$

=> Un seul point stationnaire $(x_1, x_2) = (0, 1)$

$$\nabla^2 f(x) = \begin{pmatrix} 2 & 2 \\ 2 & 4 \end{pmatrix} > 0 \quad \text{C'est un minimum}$$



Minimisation avec contraintes égalités

Résolution avec une contraintes égalité: Critère: $J = \min_{x \in \mathbb{R}^n} f(x)$

Sous la contrainte : $h(x) = 0$

Idée : Définir un nouveau critère, appelé Lagrangien

$$L(x, \lambda) = f(x) + \lambda h(x)$$

$\lambda \in \mathbb{R}^n$: paramètre de Lagrange à déterminer

Conditions au premier ordre


$$\begin{cases} \nabla L(x) = 0 \\ \nabla f(x) + \lambda \nabla h(x) = 0 \end{cases}$$

$$\frac{\partial L}{\partial \lambda}(x, \lambda) = 0 \Leftrightarrow h(x) = 0$$

$$\frac{\partial L}{\partial x_1}(x, \lambda) = 0 \Leftrightarrow \frac{\partial f}{\partial x_1}(x) + \lambda \frac{\partial h}{\partial x_1}(x) = 0$$

\vdots

$$\frac{\partial L}{\partial x_n}(x, \lambda) = 0 \Leftrightarrow \frac{\partial f}{\partial x_n}(x) + \lambda \frac{\partial h}{\partial x_n}(x) = 0$$



Minimisation avec contraintes égalités


Interprétation géométrique des conditions d'optimalité au premier ordre

$$\frac{\partial L}{\partial x}(x, \lambda) = 0 \Leftrightarrow \frac{\partial f}{\partial x}(x) = -\lambda \frac{\partial h}{\partial x}(x)$$


⇒ Le gradient de la fonction et celui de la contrainte sont colinéaires sur les points stationnaires

⇒ La courbe de niveau de la fonction et le gradient de la contrainte sont orthogonaux sur les points stationnaires


Contrainte $h(x)$



Fonction $f(x)$



Fonction $f(x)$ et contrainte $h(x)$



Minimisation avec contraintes égalités

Résolution au premier ordre:

Critère $\min_{x \in \mathbb{R}^2} f(x) = x_1^2 + 2x_2^2 + 2x_1x_2 - 2x_1 - 4x_2$

Contrainte $h(x) = (x_1 - 5)^2 + (x_2 - 5)^2 - 10^2 = 0$

Lagrangien $L(x, \lambda) = x_1^2 + 2x_2^2 + 2x_1x_2 - 2x_1 - 4x_2 + \lambda((x_1 - 5)^2 + (x_2 - 5)^2 - 10^2)$

Conditions au premier ordre pour obtenir une liste de solutions potentielles

$$\phi = \left\{ (x, \lambda) \in \mathbb{R}^2 \mid \frac{\partial L(x, \lambda)}{\partial x_1} = \frac{\partial L(x, \lambda)}{\partial x_2} = \frac{\partial L(x, \lambda)}{\partial \lambda} = 0 \right\}$$

Sélection du minimum

$$x^* = \operatorname{argmin}_{x \in \phi} f(x)$$

Minimisation avec contraintes égalités

```
clear all;
close all;
clc;

% Minimisation avec contrainte égalité
syms l x1 x2 real
Q=[1 0;1 1];
f=x1^2 + 2*x1*x2 - 2*x1 + 2*x2^2 - 4*x2;
h=(x1-15)^2+(x2-15)^2-100;

% Lagrangien
L=f+l*h;

% Recherche des points stationnaires
dL=gradient(L,[x1 x2 l]);
Stat=solve(dL,[x1 x2 l]);

X1potentiel=double(Stat.x1);
X2potentiel=double(Stat.x2);
Lpotentiel=double(Stat.l);

f=symfun(f,[x1 x2]);
F=f(X1potentiel,X2potentiel);
[fmin,i]=min(F);

fprintf('Solution : \n');
fprintf('  x1 : %.2e x2 : %.2e lambda : %.2e\n',X1potentiel(i),X2potentiel(i),F(i));
fprintf('  paramètre de Lagrange : %.2e\n',Lpotentiel(i));
fprintf('  critere : %.2e\n',F(i));
```

} Retourne une structure :
Stat.x1=[xxx;xxxx]
Stat.x2=[xxx;xxxx]
Stat.l=[xxx;xxxx]

} Crée 3 tableaux
(1 pour chaque variable)

} Calcule le minimum et l'argmin
(i: n° de la case contenant le minimum du tableau F)


Savoir-faire n°4 : Calcul Matlab

Savoir calculer un ensemble de solution potentielles
(cond. au premier ordre) et sélectionner la meilleure

[fmin,i]=min(F) : renvoie le minimum du tableau F et n° de la
case contenant ce minimum

Minimisation avec contraintes égalités

```
h=symfun(h,[x1 x2]);  
[X1, X2] = meshgrid(-50:1:50,-50:1:50);  
F = double(f(X1,X2));  
H= double(h(X1,X2));  
  
figure;  
contour(X1,X2,F,50);  
hold on;  
fc=fcontour(h,[xlim ylim],'LevelList',0);  
fc.LineWidth=1;  
fc.LineColor=[0 1 0];  
plot(X1potentiel(i),X2potentiel(i),'r*');  
xlabel('x_1');  
ylabel('x_2');  
axis square;
```



Minimisation avec contraintes égalités

Qualification des contraintes

$$\begin{aligned}\text{Critère} \quad & \min_{x \in \mathbb{R}^2} f(x_1, x_2) = x_2 \\ \text{Contrainte} \quad & h(x) = x_2^3 - x_1^4 = 0\end{aligned}$$

Résolution « manuelle » de la contrainte: $h(x) = 0 \Leftrightarrow x_2 = |x_1|^{\frac{4}{3}}$

Le problème d'optimisation réduit est: $\min_{x \in \mathbb{R}^2} f(x_1, x_2) = x_2 = |x_1|^{\frac{4}{3}}$

La solution unique est : $x_1^* = x_2^* = 0$


Que vaut le paramètre de Lagrange pour la sol optimale ?

$$\text{Lagrangien} \quad L(x_1, x_2) = x_2 + \lambda(x_2^3 - x_1^4)$$

Conditions d'optimalité au premier ordre en (x_1^*, x_2^*) :

$$\frac{\partial L}{\partial x_1}(x_1^*, x_2^*) = 0 \Leftrightarrow -4\lambda(x_1^*)^3 = 0 \quad \Rightarrow \text{Ne permet pas de conclure}$$

$$\frac{\partial L}{\partial x_2}(x_1^*, x_2^*) = 0 \Leftrightarrow 1 - 3\lambda(x_1^*)^2 = 0 \quad \Rightarrow \text{impossible}$$



/exemple issu de <http://www.rmi.ge/~kade/LecturesT.Kadeishvili/MathEconomics/Term4/>

Minimisation avec contraintes égalités

Conditions d'optimalité au premier ordre:

Soit x^* la solution du problème, et λ^* le paramètre de Lagrange associé à la ou les contraintes.

1) Une seule contrainte: $\nabla f(x^*) = -\lambda^* \nabla h(x^*)$ si $\nabla h(x^*) = 0$ la condition d'optimalité n'a plus de sens

2) Plusieurs contraintes la Jacobienne des contraintes doit être de rang plein

Les contraintes doivent être indépendantes,

S'il y a m contraintes

$$h(x) = \begin{pmatrix} h_1(x) \\ \vdots \\ h_m(x) \end{pmatrix}$$

Alors il faut que

$$\text{rang}(Dh(x^*)) = m$$

$$Dh(x^*) = \begin{pmatrix} \nabla h_1(x^*) \\ \vdots \\ \nabla h_m(x^*) \end{pmatrix} = \begin{pmatrix} \frac{\partial h_1}{\partial x_1} & \cdots & \frac{\partial h_1}{\partial x_n} \\ \vdots & & \vdots \\ \frac{\partial h_m}{\partial x_1} & \cdots & \frac{\partial h_m}{\partial x_n} \end{pmatrix}$$

Jacobienne de h

Minimisation avec contraintes égalités

Théorème: condition nécessaire d'optimalité en présence de contraintes égalité

$f : \mathbb{R}^n \rightarrow \mathbb{R}$ de classe \mathcal{C}^1 .

$h : \mathbb{R}^n \rightarrow \mathbb{R}^m$ de classe \mathcal{C}^1 .

Soit x^* solution du problème suivant

$$\min_{x \in \mathbb{R}^n} f(x) \quad \text{sous la contrainte} \quad h(x) = 0$$

Si $\text{rang}(Dh(x^*)) = m$ alors

Il existe $\lambda^* \in \mathbb{R}^m$ tel que les conditions suivantes sont vérifiées

$$L(x, \lambda) = f(x) + \lambda^T h(x)$$

$$\left. \begin{array}{ll} \frac{\partial L}{\partial x_1}(x^*, \lambda^*) = 0 \cdots \frac{\partial L}{\partial x_n}(x^*, \lambda^*) = 0 \\ \frac{\partial L}{\partial \lambda_1}(x^*, \lambda^*) = 0 \cdots \frac{\partial L}{\partial \lambda_m}(x^*, \lambda^*) = 0 \end{array} \right\} \begin{array}{l} \nabla_x L(x, \lambda) = 0 \\ \nabla_\lambda L(x, \lambda) = 0 \end{array}$$

$$\text{rang}(Dh(x^*)) = m$$

$$\Rightarrow \nabla h_i(x^*) \neq 0 \quad \forall i = 1..m$$

\Rightarrow Le nombre de contraintes ne peut pas excéder le nombre de variables : $m \leq n$

Minimisation avec contraintes inégalités

On considère maintenant le problème suivant:

$f: \mathbb{R}^n \rightarrow \mathbb{R}$ de classe \mathcal{C}^1 .

$c: \mathbb{R}^n \rightarrow \mathbb{R}$ de classe \mathcal{C}^1 .

$\min_{x \in \mathbb{R}^n} f(x)$ sous la contrainte inégalité $c(x) \leq 0$

Cas n°1 : la solution x^* est sur la contrainte


$$c(x)^* = 0$$

Les conditions d'optimalités au premier ordre précédentes sont vérifiées : il existe un paramètre de Lagrange $\mu^* \in \mathbb{R}^n$ tel que :

$$L(x^*, \mu^*) = f(x^*) + \mu^{*T} c(x^*)$$

$$\nabla f(x^*) = -\mu^* \nabla c(x^*) \quad \text{On montre que } \mu^* \geq 0$$

La condition au premier ordre $\nabla f(x^*) + \mu^* \nabla c(x^*) = 0$
est satisfaite pour $\mu^* \geq 0$.



Minimisation avec contraintes inégalités

On considère maintenant le problème suivant avec une seule contrainte inégalité:

$f: \mathbb{R}^n \rightarrow \mathbb{R}$ de classe \mathcal{C}^1 .

$c: \mathbb{R}^n \rightarrow \mathbb{R}$ de classe \mathcal{C}^1 .

$\min_{x \in \mathbb{R}^n} f(x)$ sous la contrainte inégalité $c(x) \leq 0$

Cas n°2 : la solution x^* n'est pas sur contrainte


La solution du pb non contraint est aussi solution du pb contraint

=> La contrainte n'est pas active

$$\nabla f(x^*) = 0$$

Si on pose $L(x, \mu) = f(x) + \mu^T c(x)$

La condition au premier ordre $\nabla f(x^*) + \mu^* \nabla c(x^*) = 0$
est satisfaite pour $\mu^* = 0$.



Minimisation avec contraintes inégalités

On considère maintenant le problème suivant avec une seule contrainte inégalité:

$f : \mathbb{R}^n \rightarrow \mathbb{R}$ de classe \mathcal{C}^1 .

$c : \mathbb{R}^n \rightarrow \mathbb{R}$ de classe \mathcal{C}^1 .

$\min_{x \in \mathbb{R}^n} f(x)$ sous la contrainte inégalité $c(x) \leq 0$

Résumé des deux cas: $\mu^* \in \mathbb{R}$

Lagrangien: $L(x, \mu, \lambda) = f(x) + \mu c(x)$

Stationnarité: $\nabla L(x, \lambda) = 0 \Leftrightarrow \nabla f(x^*) + \mu_j^* \nabla c_j(x^*) = 0$

Admissibilité primale: $c(x^*) \leq 0$

Admissibilité duale: $\mu^* \geq 0$

Complémentarité: $\mu^* c(x^*) = 0$

Minimisation avec contraintes égalités & inégalités

On considère maintenant le problème suivant avec **p contraintes inégalité** :

$$f : \mathbb{R}^n \rightarrow \mathbb{R} \text{ de classe } \mathcal{C}^1.$$

$$c : \mathbb{R}^n \rightarrow \mathbb{R}^p \text{ de classe } \mathcal{C}^1.$$

$$\min_{x \in \mathbb{R}^n} f(x) \text{ sous la contrainte inégalité } c(x) \leq 0$$

De manière analogue au cas précédent, la solution (x^*, μ^*) vérifie :

$$\mu^* = (\mu_1^*, \dots, \mu_p^*)^T$$

Lagrangien: $L(x, \mu, \lambda) = f(x) + \mu^T c(x)$

Stationnarité: $\nabla L(x, \lambda) = 0 \Leftrightarrow \nabla f(x^*) + \sum_{j=1}^p \mu_j^* \nabla c_j(x^*) = 0$

Admissibilité primale: $c(x^*) \leq 0 \quad i = 1..p$

Admissibilité duale: $\mu_i^* \geq 0 \quad i = 1..p$

Complémentarité: $\mu_i^* c_i(x^*) = 0 \quad i = 1..p$

Problème: la qualification des contraintes doit être étudiée uniquement pour les contraintes inégalité actives. Or elles ne sont pas connues à l'avance.

Minimisation avec contraintes égalités & inégalités

On considère maintenant le problème suivant avec p contraintes inégalité et m contraintes égalité :

$$f : \mathbb{R}^n \rightarrow \mathbb{R} \quad h : \mathbb{R}^n \rightarrow \mathbb{R}^m \quad c : \mathbb{R}^n \rightarrow \mathbb{R}^p \quad \text{toutes de classe } \mathcal{C}^1.$$

$$\min_{x \in \mathbb{R}^n} f(x)$$

sous les contraintes:

$$c(x) \leq 0 \quad h(x) = 0$$

Conditions d'optimalité de Karush, Kuhn et Tucker , la solution (x^*, λ^*, μ^*) vérifie :

Lagrangien:

$$L(x, \mu, \lambda) = f(x) + \mu^T c(x) + \lambda^T h(x)$$

$$\lambda^* = (\lambda_1^*, \dots, \lambda_m^*)^T$$
$$\mu^* = (\mu_1^*, \dots, \mu_p^*)^T$$

Stationnarité:

$$\nabla L(x, \mu, \lambda) = 0 \Leftrightarrow \nabla f(x^*) + \sum_{j=1}^p \mu_j^* \nabla c_j(x^*) + \sum_{i=1}^m \lambda_i^* \nabla h_i(x^*) = 0$$

Admissibilité primale:

$$h(x^*) = 0 \quad i = 1..m$$

$$c(x^*) \leq 0 \quad i = 1..p$$

Admissibilité duale:

$$\mu_i^* \geq 0 \quad i = 1..p$$

Complémentarité:

$$\mu_i^* c_i(x^*) = 0 \quad i = 1..p$$

Problème: la qualification des contraintes doit être étudiée uniquement pour les contraintes inégalité actives. Or elles ne sont pas connues à l'avance.

=> Non traité dans ce cours

Chapitre 1 - Concepts


- 1) Problématiques abordées en cours
- 2) Ecriture d'un problème d'optimisation
- 3) Minimisation non contrainte
- 4) Minimisation avec contraintes
- 5) Convexité

Convexité du problème d'optimisation

Ensemble convexe: une ensemble \mathcal{C} est dite convexe si


$$\forall x, y \in \mathcal{C} \quad \forall \alpha \in [0,1] \quad \alpha x + (1-\alpha)y \in \mathcal{C}$$

Ensemble convexe



Le segment qui relie 2 points x, y de l'ensemble \mathcal{C} appartient intégralement à l'ensemble \mathcal{C}

Ensemble non convexe




Le segment qui relie 2 points x, y de l'ensemble \mathcal{C} n'appartient pas intégralement à l'ensemble \mathcal{C}

Convexité du problème d'optimisation

Fonction convexe: une fonction $f : \mathbb{R}^n \rightarrow \mathbb{R}$ est dite convexe si

- $\text{dom}(f)$ est un ensemble convexe
- $f(\alpha x + (1 - \alpha)y) \leq \alpha f(x) + (1 - \alpha)f(y) \quad \forall x, y \in \text{dom}(f), 0 \leq \alpha \leq 1$



Convexité du problème d'optimisation

Soit le problème \mathcal{P} :

$$f : \mathbb{R}^n \rightarrow \mathbb{R} \quad h : \mathbb{R}^n \rightarrow \mathbb{R}^m \quad c : \mathbb{R}^n \rightarrow \mathbb{R}^p$$

$$\min_{x \in \mathbb{R}^n} f(x)$$

sous les contraintes:

$$c(x) \leq 0 \quad h(x) = 0$$

Le problème \mathcal{P} est dit convexe si :

- f est une fonction convexe
- L'espace des solutions admissibles \mathcal{C} est convexe

$$\mathcal{C} = \{x \in \mathbb{R}^n \mid c(x) \leq 0; h(x) = 0\}$$

Le problème \mathcal{P} est convexe, alors les conditions d'optimalités sont nécessaire et suffisantes.

Cf : <https://see.stanford.edu/Course/EE364A> pour plus d'information sur les fonctions/ensembles convexes

A quoi servent en pratique les conditions d'optimalités ?

En pratique :

- La convexité du problème d'optimisation est difficilement étudiable
- La résolution exacte des conditions d'optimalité s'avère rapidement difficile / infaisable

$$\min_{x \in \mathbb{R}} f(x) = x^5 + x^3 + 2x - 1$$

$$\frac{\partial f}{\partial x}(x) = 5x^4 + 3x^2 + 2 = 0 \quad \Rightarrow \text{Ne peut pas être résolu}$$

En pratique :

- Les conditions KKT sont un très bon indicateur de la qualité d'une solution obtenue par un algorithme numérique
- On passe d'un problème contraint à un problème non contraint